TEK-UP, École Supérieure Privée d'Ingénierie et de Technologies

mini-projet Séries temporelles

GoldSilver Analytics

Modélisation, prévision et volatilité de l'or et de l'argent

ARIMA, VAR, cointégration, GARCH, LSTM et GRU appliqués aux fonds GLD et SLV (2010 à 2025)

Rapport de projet

Réalisé par :
Nourchene Dridi,
Yomna Haouel
ING5-SDIAF-C

Encadré par : M. Ahmed Dhouibi

Octobre 2026

Introduction

Thématique choisie

Le projet porte sur les métaux précieux. L'or et l'argent dépendent des mêmes facteurs (dollar, taux d'intérêt, aversion au risque), mais l'argent est aussi un métal industriel et il est beaucoup plus volatil. Ce couple permet d'appliquer sur les mêmes données les modèles univariés, multivariés, de volatilité et les réseaux de neurones.

Séries retenues

Nous utilisons deux fonds cotés adossés à du métal physique : GLD pour l'or et SLV pour l'argent. Les données sont quotidiennes et proviennent de Yahoo Finance.

Tableau 1 : Séries retenues

Symbole	Instrument	Sous-jacent	Période	Séances	Variable modélisée
GLD	SPDR Gold Shares	Or	04/01/2010 au 31/12/2025	4 024	Prix de clôture ajusté
SLV	iShares Silver Trust	Argent	04/01/2010 au 31/12/2025	4 024	Prix de clôture ajusté



Figure 1 : Prix ajustés de GLD et SLV sur la période d'apprentissage

Les deux prix montent jusqu'en 2011, baissent jusqu'en 2015, puis remontent à partir de 2019, avec des variations beaucoup plus fortes pour SLV.

Question de modélisation

Le projet cherche à répondre à trois questions :

1. Peut-on prévoir les prix de GLD et SLV à 5 et 10 séances mieux qu'en supposant que le prix reste inchangé ? Les réseaux LSTM et GRU font-ils mieux que les modèles classiques ?
2. Les deux métaux sont-ils liés : l'un aide-t-il à prévoir l'autre, et ont-ils un équilibre de long terme ?
3. Comment évolue leur volatilité, et le modèle GARCH donne-t-il des intervalles de prévision fiables ?

Les calculs sont faits dans le notebook `notebooks/01_or_argent.ipynb`. Les modèles classiques sont

refaits en R dans `scripts_R/02_modeles_classiques.R` pour vérifier les résultats.

1. Collecte et préparation des données

1.1. Collecte

Les données sont téléchargées avec `yfinance` du 01/01/2010 au 31/12/2025. Pour chaque fonds, nous gardons les colonnes Open, High, Low, Close, Adj Close et Volume, enregistrées dans `data/raw/`. Nous modélisons le prix de clôture ajusté.

La colonne « Adj Close » correspond au prix de clôture ajusté par Yahoo Finance pour tenir compte notamment des divisions d'actions et des distributions éventuelles. Nous utilisons l'ajustement fourni sans le recalculer. Les données brutes utilisées pour produire les résultats du rapport sont archivées dans `data/raw/`. Le notebook effectue un nouveau téléchargement à chaque exécution ; une révision de l'historique par le fournisseur peut donc modifier légèrement les résultats.

1.2. Contrôle de qualité et découpage

Tableau 2 : Contrôles de qualité et découpage temporel

Contrôle	GLD	SLV
Nombre de lignes	4 024	4 024
Dates dupliquées	0	0
Valeurs manquantes	0	0
Prix nuls ou négatifs	0	0
Apprentissage (90 %)	3 621 séances, du 04/01/2010 au 22/05/2024	Mêmes dates
Test (10 %)	403 séances, du 23/05/2024 au 31/12/2025	Mêmes dates

Les données sont complètes : aucune correction n'a été nécessaire. Les deux fonds ont exactement les mêmes dates. Le découpage est chronologique et la période de test n'est jamais utilisée pour choisir ou régler un modèle. Python et R lisent les mêmes fichiers `prix_train.csv` et `prix_test.csv`.

1.3. Rendements

Les rendements logarithmiques en pourcentage sont calculés ainsi :

$$r_t = 100 \times \ln(P_t / P_{t-1})$$

On obtient 3 620 rendements d'apprentissage par actif. Les log-prix servent aux tests de racine unitaire, à l'ARIMA et à la cointégration. Les rendements servent au VAR, au GARCH et aux réseaux.

2. Analyse exploratoire

Toute l'analyse exploratoire est faite sur l'apprentissage seulement.

2.1. Évolution des prix

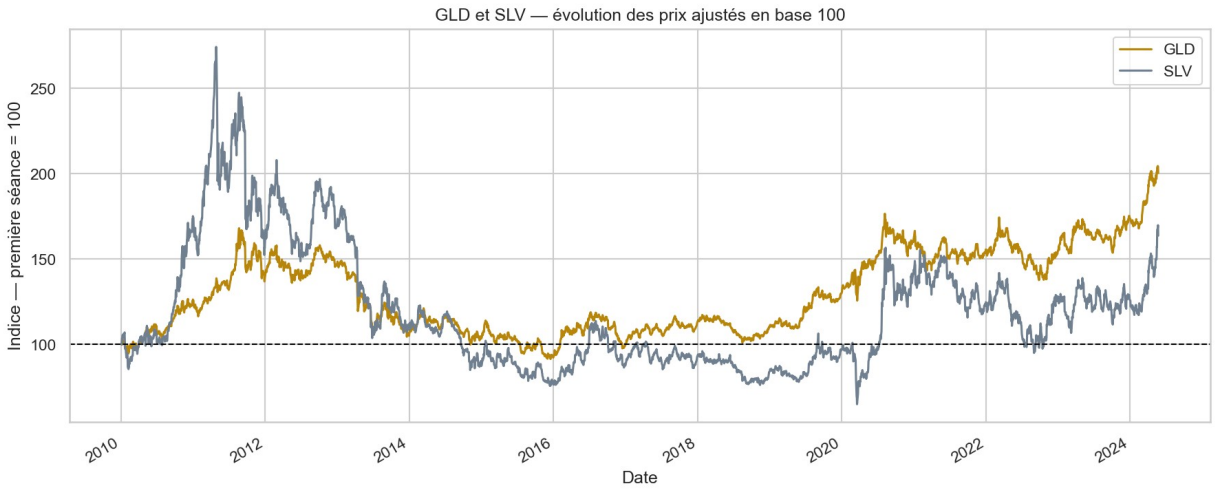


Figure 2 : Prix de GLD et SLV en base 100

Les deux fonds suivent les mêmes grandes phases, mais SLV amplifie chaque mouvement et aucun des deux ne revient vers un niveau moyen fixe.

2.2. Rendements

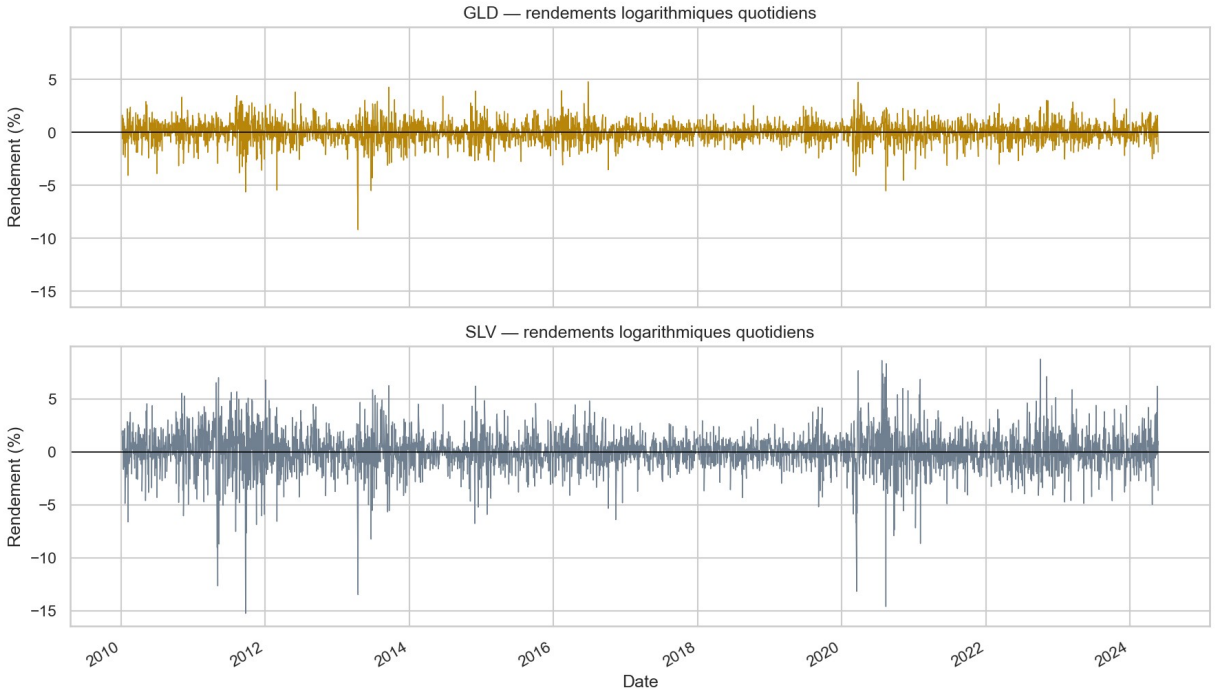


Figure 3 : Rendements logarithmiques quotidiens (%)

Les rendements varient autour de zéro, avec des périodes agitées (2011, 2013, 2020) et des périodes calmes.

Tableau 3 : Statistiques descriptives des rendements (%)

Actif	Moyenne	Écart-type	Minimum	Maximum	Asymétrie	Excès de kurtosis
GLD	0,0192	0,9773	−9,19	4,79	−0,501	4,996
SLV	0,0136	1,8208	−15,25	8,75	−0,717	7,080

SLV est presque deux fois plus volatil que GLD (1,82 % contre 0,98 % par séance). Les deux distributions ont une asymétrie négative et des queues épaisses : les fortes baisses sont plus fréquentes qu'avec une loi normale. La corrélation entre les deux rendements est de 0,7907.

2.3. Stationnarité

Le test ADF a pour hypothèse nulle la présence d'une racine unitaire, et le test KPSS la stationnarité. Les log-prix sont testés avec constante (c) et avec constante et tendance (ct).

Tableau 4 : Tests ADF et KPSS (Python, avec contrôle en R)

Actif	Série	Spéc.	ADF stat.	ADF p	KPSS stat.	KPSS p	Conclusion	R : ADF p / KPSS p
GLD	Log-prix	c	−0,97	0,764	3,439	≤ 0,01	Non stationnaire	0,84 / ≤ 0,01
GLD	Log-prix	ct	−1,46	0,841	1,536	≤ 0,01	Non stationnaire	
GLD	Rendement	c	−60,61	< 0,0001	0,138	≥ 0,10	Stationnaire	0,01 / ≥ 0,10
SLV	Log-prix	c	−1,85	0,356	1,970	≤ 0,01	Non stationnaire	0,64 / ≤ 0,01
SLV	Log-prix	ct	−1,82	0,693	1,309	≤ 0,01	Non stationnaire	
SLV	Rendement	c	−59,03	< 0,0001	0,101	≥ 0,10	Stationnaire	0,01 / ≥ 0,10

Les tests ADF et KPSS donnent des résultats concordants en Python et en R : ils sont compatibles avec des log-prix non stationnaires et des rendements stationnaires. Cela soutient une intégration d'ordre 1 des log-prix et justifie une première différenciation (d = 1) dans l'ARIMA. Ces tests ne garantissent toutefois pas la stabilité de toutes les propriétés de la série.

2.4. Autocorrélations

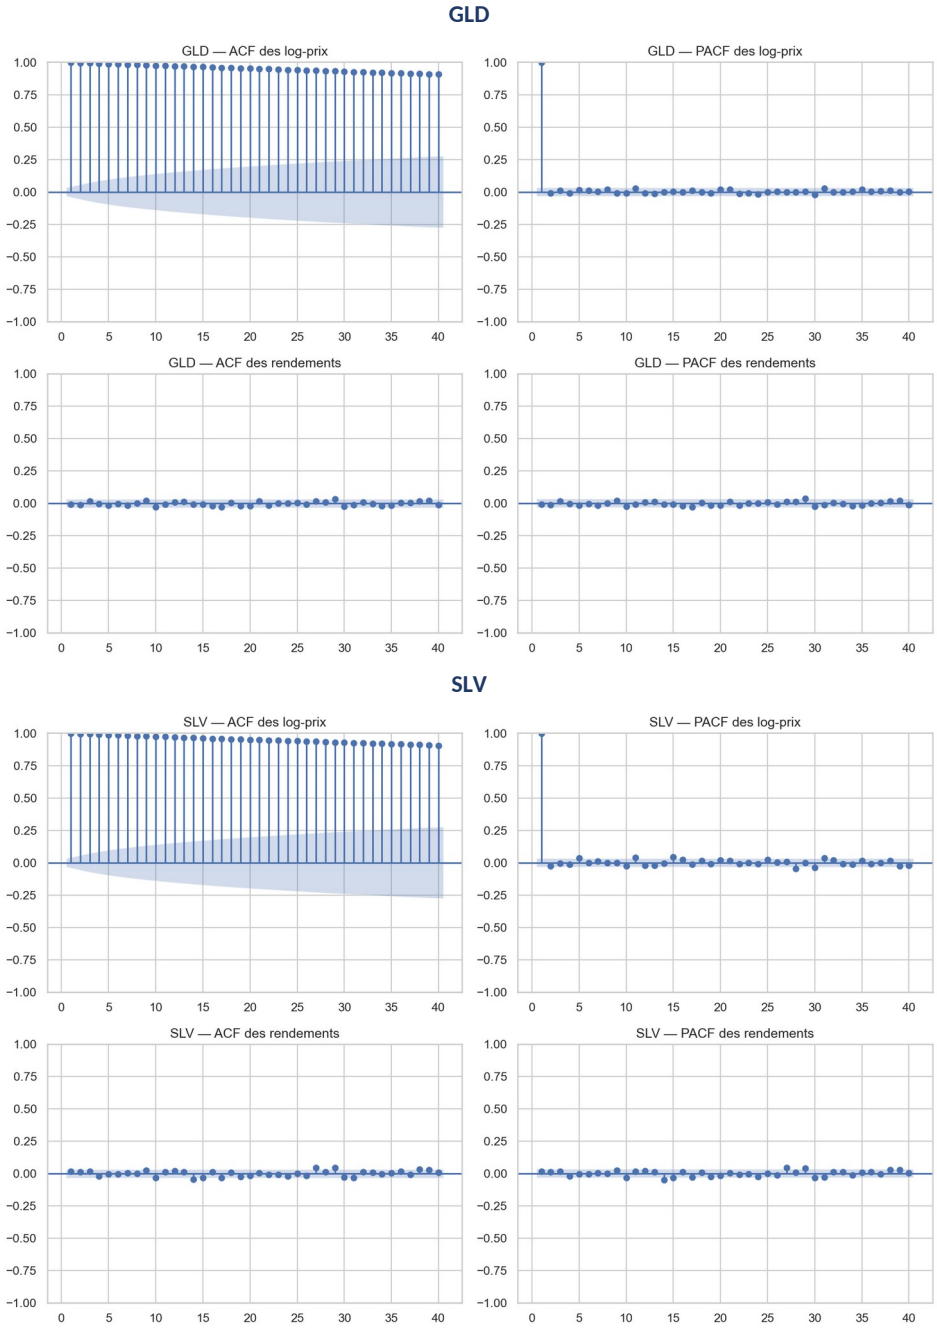


Figure 4 : ACF et PACF des log-prix (en haut) et des rendements (en bas)

L'ACF des log-prix décroît très lentement alors que celle des rendements est presque nulle, ce qui est typique d'une marche aléatoire.

Aucun des dix premiers retards n'est significatif pour GLD. Pour SLV, seule la PACF au retard 10 l'est légèrement, ce qui peut être dû au hasard. Le premier modèle candidat est donc ARIMA(0,1,0).

2.5. Valeurs extrêmes

La règle de l'écart interquartile signale 170 rendements extrêmes pour GLD (4,70 %) et 229 pour SLV (6,33 %). Les plus fortes variations sont des baisses : −9,19 % pour GLD le 15/04/2013 et −15,25 % pour SLV le 23/09/2011. Trois dates sont communes aux deux actifs : 23/09/2011, 15/04/2013 et 11/08/2020. Ces valeurs sont réelles, donc nous les gardons. Elles justifient l'usage d'une loi de Student dans le GARCH.

2.6. Saisonnalité

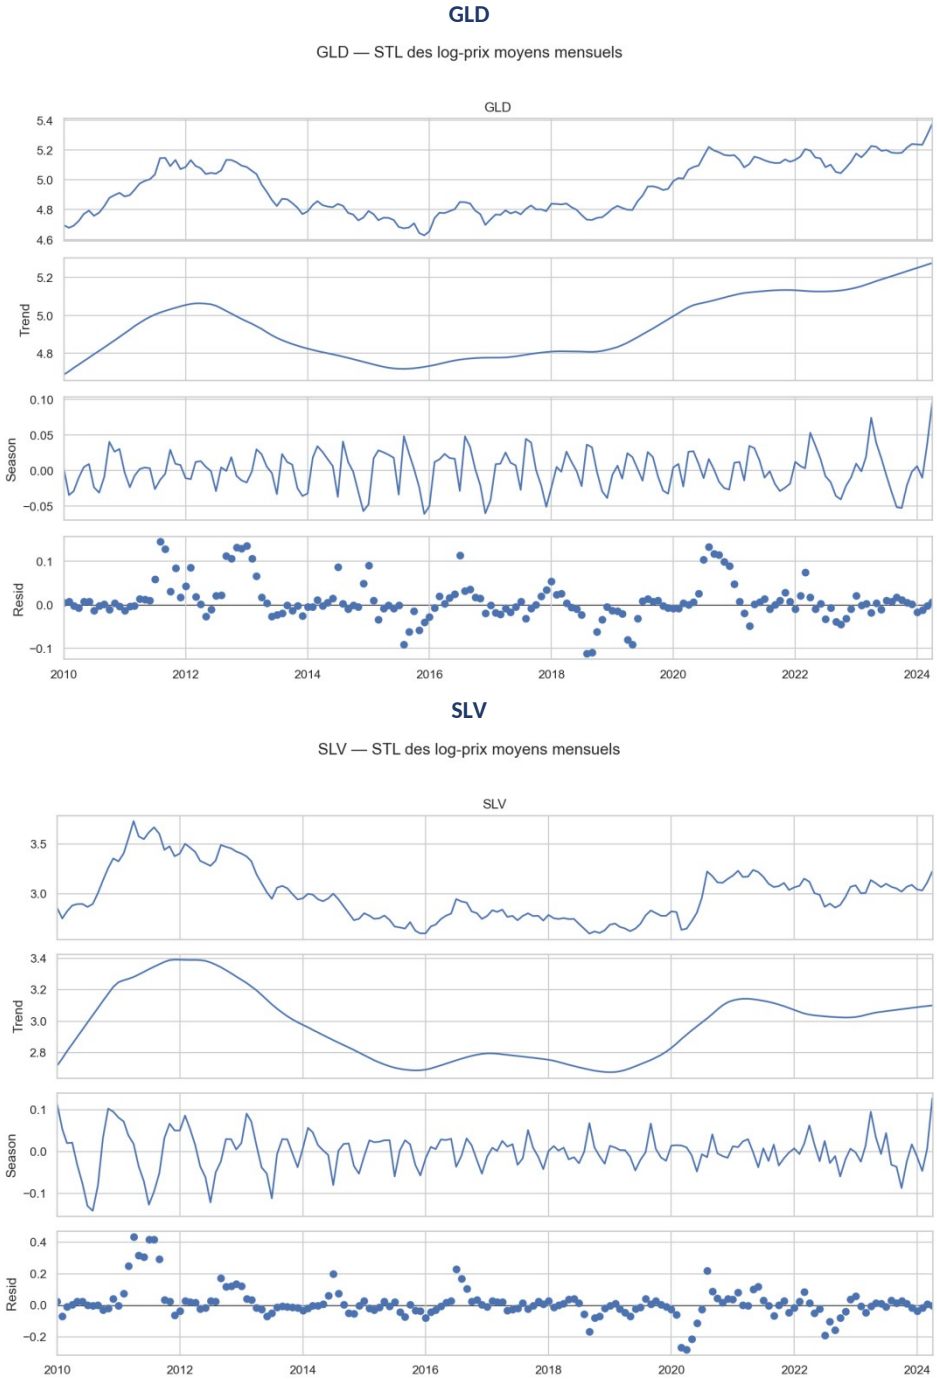


Figure 5 : Décomposition STL des log-prix mensuels (période de 12 mois)

La tendance domine et la composante saisonnière est faible et change d'une année à l'autre.

L'écart-type de la composante saisonnière (0,026 pour GLD et 0,044 pour SLV) est même plus faible que celui du résidu (0,045 et 0,098). La décomposition mensuelle ne fournit pas d'élément suffisant en faveur d'une saisonnalité annuelle stable. Nous ne retenons donc pas de SARIMA. Cette analyse ne permet toutefois pas d'exclure tous les effets calendaires possibles sur les données quotidiennes.

3. Modèles classiques

3.1. ARIMA

Huit modèles ARIMA de petit ordre, avec et sans dérive, sont estimés sur les log-prix. Une recherche automatique (`auto_arima`) sert de contrôle.

Tableau 5 : Comparaison des modèles ARIMA (ligne surlignée : modèle retenu)

Modèle	Dérive	AIC GLD	BIC GLD	AIC SLV	BIC SLV
ARIMA(0,1,0)	non	−23 232,4	−23 226,2	−18 728,3	−18 722,1
ARIMA(0,1,0)	oui	−23 231,8	−23 219,4	−18 726,5	−18 714,1
ARIMA(1,1,0)	non	−23 230,7	−23 218,3	−18 727,5	−18 715,1
ARIMA(1,1,0)	oui	−23 230,1	−23 211,5	−18 725,7	−18 707,1
ARIMA(0,1,1)	non	−23 230,7	−23 218,3	−18 727,5	−18 715,1
ARIMA(0,1,1)	oui	−23 230,1	−23 211,5	−18 725,7	−18 707,1
ARIMA(1,1,1)	non	−23 228,2	−23 209,6	−18 724,6	−18 706,0
ARIMA(1,1,1)	oui	−23 227,6	−23 202,9	−18 722,8	−18 698,0

ARIMA(0,1,0) sans dérive a le plus petit AIC et le plus petit BIC pour les deux actifs, et la recherche automatique choisit le même modèle. Ce modèle représente une marche aléatoire sans dérive des log-prix. La prévision du log-prix est égale au dernier log-prix observé. En l'exponentiant, nous obtenons une prévision de prix inchangé, utilisée comme référence. Cette transformation ne donne pas automatiquement l'espérance du prix futur.

Tableau 6 : Diagnostic des résidus de ARIMA(0,1,0)

Actif	Ljung–Box p (10)	Ljung–Box p (20)	Jarque–Bera p	ARCH-LM p (10)
GLD	0,6708	0,7343	< 0,0001	< 0,0001
SLV	0,4142	0,0487	< 0,0001	< 0,0001

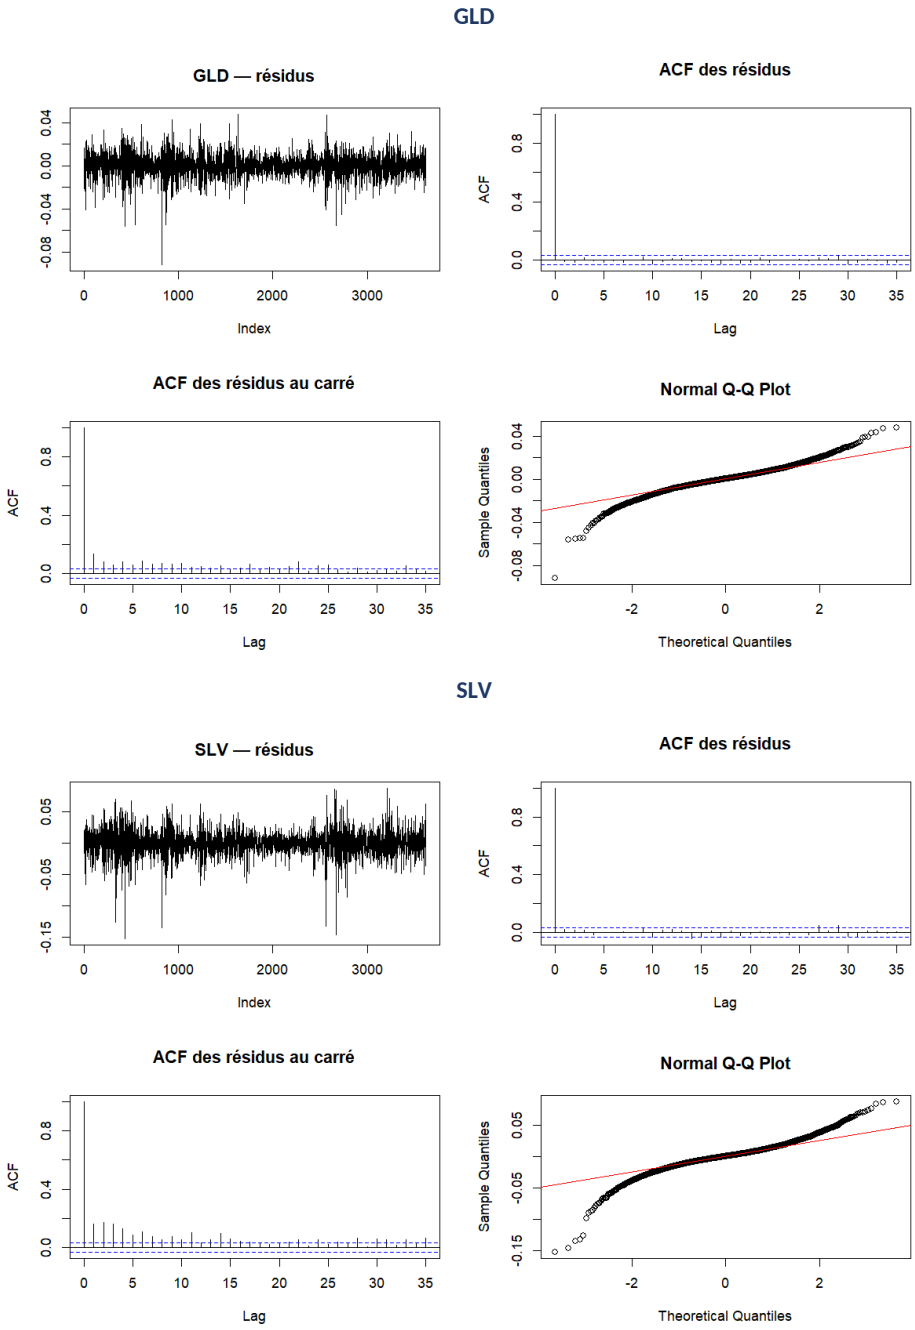


Figure 6 : Résidus de ARIMA(0,1,0) en R

L'autocorrélation résiduelle est faible, mais Ljung–Box détecte une dépendance pour SLV à 20 retards. L'ACF des carrés est significative et le QQ-plot montre des queues épaisses.

Pour SLV, Ljung–Box rejette de peu à 20 retards (p = 0,0487). La normalité et l'absence d'effet ARCH sont rejetées pour les deux actifs. Le modèle constitue une référence simple pour prévoir les log-prix. Ses diagnostics restent imparfaits : une autocorrélation résiduelle est détectée pour SLV à 20 retards, et les tests ARCH indiquent une variance conditionnelle variable pour les deux actifs. Ces résultats motivent l'estimation d'un GARCH.

3.2. VAR et causalité de Granger

Tableau 7 : Choix du nombre de retards du VAR (extrait)

Retards	AIC	BIC	HQIC	FPE
0	0,17124	0,17467	0,17246	1,18677
1	0,17168	0,18197	0,17535	1,18730
2	0,17282	0,18998	0,17894	1,18866
3	0,17386	0,19787	0,18242	1,18989
10	0,17814	0,25017	0,20380	1,19499

Les quatre critères choisissent VAR(0). Ce modèle prévoit simplement le rendement moyen de l'apprentissage (0,0192 % pour GLD et 0,0136 % pour SLV). En prix, c'est une marche aléatoire avec dérive.

VAR(0) ne contient aucun terme retardé : il prévoit des rendements moyens constants et ne modélise pas d'interactions dynamiques entre les actifs. VAR(1) est estimé en complément pour examiner ces interactions et effectuer les tests de Granger.

Un VAR(1) est estimé pour tester la causalité de Granger. Aucun coefficient retardé n'est significatif. Avec un retard, l'absence de causalité n'est pas rejetée au seuil de 5 %, dans les deux sens : SLV vers GLD (p = 0,6889) et GLD vers SLV (p = 0,6726). Les rendements des deux actifs sont fortement corrélés le même jour. Toutefois, les tests de Granger avec un retard ne détectent pas d'apport prédictif d'un actif pour l'autre, au seuil de 5 %. Cette conclusion concerne le modèle et le retard étudiés ; elle n'exclut pas toute relation prédictive possible.

Les résidus des deux VAR restent autocorrélés à 20 retards (p ≈ 0,01), non normaux et avec des effets ARCH.

3.3. Cointégration

Tableau 8 : Tests de cointégration sur les log-prix

Test	Hypothèse	Statistique	Valeur critique 5 %	p-value	Décision
Engle–Granger	GLD expliqué par SLV	−0,660	−3,338	0,9508	Pas de cointégration
Engle–Granger	SLV expliqué par GLD	−1,792	−3,338	0,6334	Pas de cointégration
Johansen (R)	r = 0	7,14	19,96		Pas de cointégration
Johansen (R)	r <= 1	2,41	9,24		Pas de cointégration

Avec les spécifications retenues, les deux tests ne détectent pas de cointégration entre les log-prix. Nous n'estimons donc pas de VECM.

3.4. Volatilité : GARCH

Comme les résidus ont des effets ARCH, nous estimons un GARCH(1,1) sur les rendements, avec une moyenne nulle et une loi de Student pour les queues épaisses :

$r_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$, z_t suit une loi de Student standardisée, de moyenne nulle et de variance unitaire.

Cela rend cohérente l'interprétation de σ_t comme volatilité conditionnelle.

Tableau 9 : Paramètres du GARCH(1,1) Student en Python et en R

Actif	Logiciel	ω	α	β	α + β	ν (Student)
GLD	Python	0,0115	0,0414	0,9477	0,9891	4,89
GLD	R	0,0116	0,0419	0,9472	0,9890	4,90
SLV	Python	0,0179	0,0335	0,9630	0,9965	4,12
SLV	R	0,0179	0,0337	0,9628	0,9965	4,13

Python et R donnent les mêmes paramètres. La persistance α + β est très proche de 1 (0,989 pour GLD et 0,996 pour SLV) : un choc de volatilité dure longtemps. Le degré de liberté ν (4,9 et 4,1) confirme les queues épaisses.

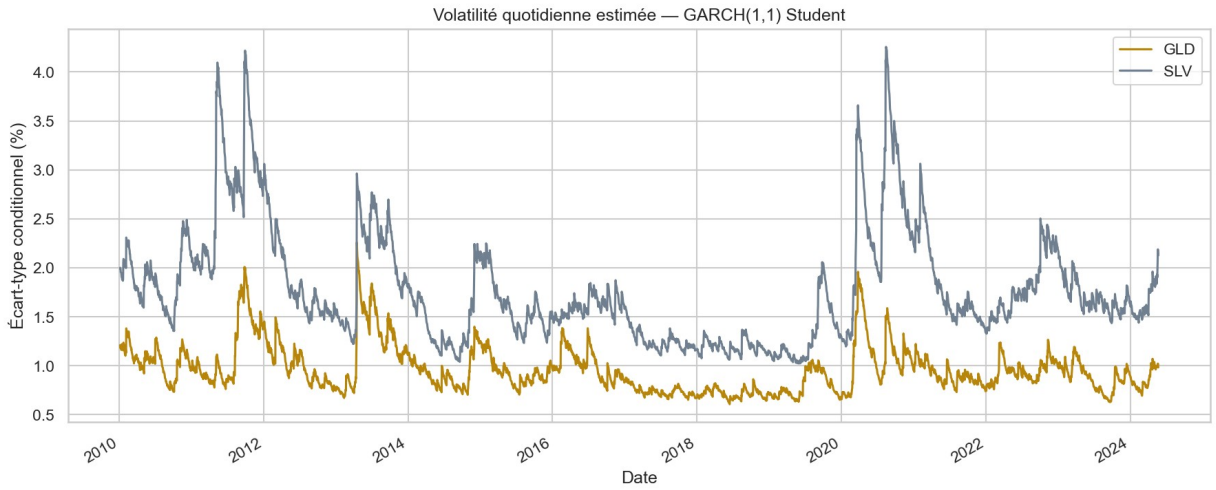


Figure 7 : Volatilité conditionnelle estimée par GARCH(1,1)

La volatilité de SLV est toujours au-dessus de celle de GLD, avec des pics en 2011, en avril 2013 et en 2020 qui correspondent aux fortes baisses vues plus haut.

Tableau 10 : Comparaison du GARCH(1,1) avec d'autres modèles de volatilité

Actif	Modèle	AIC	BIC	Ljung-Box z^2 p (10)	ARCH-LM p (10)	γ (p-value)
GLD	GARCH(1,1)	9 421,9	9 446,6	0,0326	0,0489	
GLD	GARCH(2,1)	9 419,4	9 450,4	< 0,0001	< 0,0001	
GLD	GARCH(1,2)	9 423,9	9 454,8	0,0325	0,0488	
GLD	GJR-GARCH(1,1,1)	9 416,4	9 447,3	0,0005	0,0010	−0,0276 (0,0086)
SLV	GARCH(1,1)	13 546,7	13 571,5	< 0,0001	< 0,0001	
SLV	GARCH(2,1)	13 548,7	13 579,7	< 0,0001	< 0,0001	
SLV	GARCH(1,2)	13 548,1	13 579,0	< 0,0001	< 0,0001	
SLV	GJR-GARCH(1,1,1)	13 542,3	13 573,2	< 0,0001	< 0,0001	−0,0222 (0,0175)

Le GARCH(1,1) réduit fortement les effets ARCH, mais un effet résiduel subsiste : il est à la limite du seuil de 5 % pour GLD en Python (ARCH-LM p = 0,049) et nettement significatif pour SLV (p < 0,0001). Le modèle n'est donc pas parfaitement validé, surtout pour SLV. Les autres ordres n'améliorent pas le BIC. Le GJR-GARCH améliore l'AIC et son coefficient γ est négatif et significatif : les hausses augmentent un peu plus la volatilité que les baisses. Ce résultat ne suffit pas, à lui seul, à démontrer un rôle de valeur refuge. Le BIC préfère le GARCH(1,1), que nous gardons comme modèle de référence.

3.5. Vérification en R

Tableau 11 : Comparaison des résultats Python et R

Étape	Python	R	Résultat
Stationnarité	statsmodels	tseries	Mêmes conclusions
ARIMA	statsmodels, pmdarima	forecast	Même modèle, mêmes AIC
VAR et Granger	statsmodels	vars	Mêmes retards, mêmes p-values
Cointégration	Engle–Granger	Johansen (urca)	Pas de cointégration
GARCH(1,1) Student	arch	rugarch	Paramètres égaux à 0,001 près
Prévisions ARIMA et VAR	394 origines	394 origines	Métriques identiques à 6 décimales

4. Réseaux récurrents : LSTM et GRU

4.1. Préparation

Les réseaux prévoient ensemble les rendements de GLD et SLV de la séance suivante, à partir des 30 séances précédentes. L'apprentissage est découpé dans l'ordre : 2 896 séances pour entraîner (jusqu'au 07/07/2021) et 724 pour valider (jusqu'au 22/05/2024).

Pour éviter toute fuite d'information, le `StandardScaler` est ajusté seulement sur la partie d'entraînement, chaque fenêtre ne contient que des données passées, et les séquences ne sont pas mélangées.

4.2. Architecture

Tableau 12 : Configuration des réseaux

Élément	LSTM	GRU
Architecture	LSTM(32) puis Dense(2)	GRU(32) puis Dense(2)
Paramètres	4 546	3 522
Entraînement	Adam, taux 0,001, perte MSE, lots de 32	Identique
Arrêt anticipé	Patience de 10 époques	Identique
Meilleure époque (validation)	7	13
Époques du modèle final	2	4
Graine aléatoire	42	42

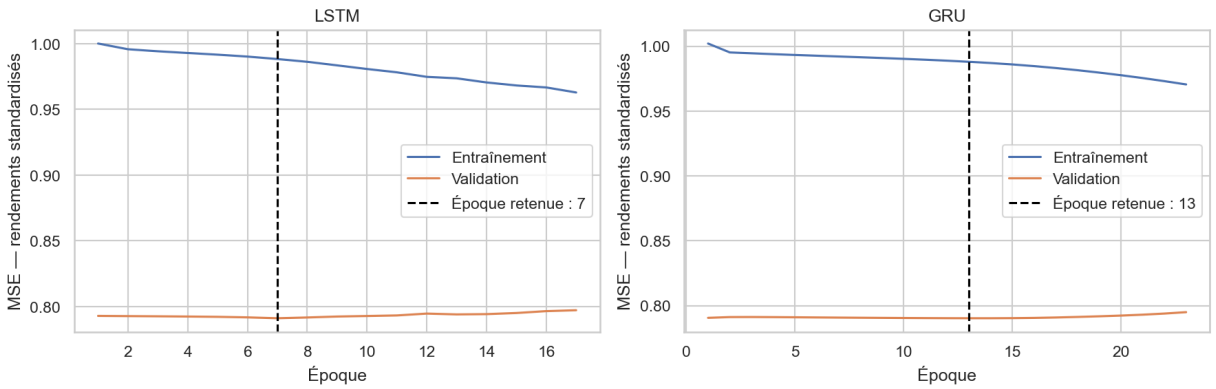


Figure 8 : Courbes d'apprentissage des réseaux

L'erreur d'entraînement baisse alors que l'erreur de validation reste plate puis remonte : les réseaux

apprennent du bruit, et l'arrêt anticipé limite ce surapprentissage.

La fenêtre de 30 séances représente environ six semaines boursières. Une seule couche de 32 unités limite la complexité et permet une comparaison simple entre LSTM et GRU. Aucun dropout n'est utilisé ; l'arrêt anticipé sert à limiter le surapprentissage pendant la validation. Ces réglages constituent un choix de départ raisonnable, mais leur optimalité n'a pas été démontrée par une recherche exhaustive.

4.3. Validation

Les réseaux sont comparés à une prévision de rendement nul (prix inchangé), d'abord sur la validation, puis par une validation croisée temporelle avec trois découpages de 400 séances.

Tableau 13 : MSE des rendements en validation (cases surlignées : moins bon que le rendement nul)

Actif	Modèle	Validation simple	Écart	Validation croisée	Écart
GLD	Rendement nul	0,7655	référence	0,9178	référence
GLD	LSTM	0,7612	−0,57 %	0,9208	0,33 %
GLD	GRU	0,7600	−0,72 %	0,9204	0,28 %
SLV	Rendement nul	2,8342	référence	3,9097	référence
SLV	LSTM	2,8259	−0,29 %	3,9074	−0,06 %
SLV	GRU	2,8245	−0,34 %	3,9116	0,05 %

Sur la validation simple, les réseaux gagnent moins de 1 %. En validation croisée, ce gain disparaît : pour GLD, les deux réseaux font un peu moins bien que le rendement nul, et pour SLV seul le LSTM gagne, de 0,06 %. Un entraînement prend de 13 à 42 secondes.

La validation croisée temporelle évalue les rendements à une séance. L'évaluation finale porte sur les prix à cinq et dix séances, obtenus par prévision récursive. La validation croisée ne vérifie donc pas directement la robustesse à ces deux horizons. La sensibilité aux graines aléatoires n'a pas non plus été étudiée.

4.4. Modèles finaux

Les réseaux sont réentraînés sur tout l'apprentissage, avec un nombre d'époques égal à la médiane des trois découpages (2 pour le LSTM, 4 pour le GRU). Aucun modèle hybride n'a été implémenté. Pour l'ARIMA(0,1,0) sans dérive retenu, les innovations correspondent aux différences des log-prix, donc aux rendements à un facteur d'échelle près. Un réseau appliqué à ces innovations serait ainsi très proche de l'approche utilisée. D'autres constructions hybrides restent possibles, mais n'ont pas été étudiées.

5. Utilisation des LLM

5.1. Protocole

Trois consultations ont été faites avec ChatGPT le 9 octobre 2026, après l'estimation des modèles et dans la conversation de travail du projet. Le LLM avait donc déjà vu une partie des résultats : ses réponses ne sont pas indépendantes. La synthèse des résultats (`01_synthese.txt`) a aussi été rédigée avec son aide. Chaque prompt donne les chiffres exacts et interdit d'inventer des résultats. Les prompts sont en annexe et les réponses complètes sont dans `reports/llm/`.

Nous ne disposons pas d'une interprétation humaine indépendante archivée avant les consultations. La comparaison humain/LLM est donc rétrospective et ne satisfait pas entièrement cette exigence du cahier des charges. Les critiques présentées évaluent la cohérence des réponses avec les résultats calculés, plutôt que leur apport face à une analyse humaine préalable indépendante.

5.2. Consultation 1 : hypothèses de modèles

Le LLM a reçu seulement les statistiques descriptives et les tests de stationnarité. Il propose ARIMA(0,1,0), un VAR, un VECM seulement en cas de cointégration, un GARCH(1,1) Student et un GJR-GARCH. Il donne aussi une méthode correcte pour comparer les réseaux sans fuite d'information. Ces propositions sont justes et ont toutes été testées. Il ne choisit cependant pas les ordres des modèles, et une loi de Student symétrique ne rend pas compte de l'asymétrie observée.

5.3. Consultation 2 : explication pour un décideur

Le LLM a reçu les métriques du test, les tests de Diebold–Mariano et les couvertures GARCH. Son texte est clair et fidèle aux chiffres. Il explique bien que le VAR(0) n'utilise aucun rendement passé et qu'une différence non significative ne prouve pas que deux modèles sont équivalents. Il oublie que les 394 origines se chevauchent, et il ne cherche pas à expliquer pourquoi les réseaux battent le prix inchangé.

5.4. Consultation 3 : recommandations simulées

Le LLM devait se placer au 22/05/2024 et proposer une position pour chaque actif. Il recommande de ne pas investir, car les hausses prévues (+0,05 % à +0,25 %) sont très petites face à la largeur des intervalles GARCH. Ce raisonnement est cohérent, mais la conversation contenait déjà les résultats du test, donc on ne peut pas exclure leur influence.

5.5. Comparaison avec notre analyse

Tableau 14 : Réponses du LLM et résultats du projet

Point	Réponse du LLM	Résultat du projet	Verdict
Modèle de moyenne	ARIMA(0,1,0) comme référence	ARIMA(0,1,0) retenu	Correct
Liens entre actifs	VAR à tester, VECM si cointégration	VAR(0), pas de Granger, pas de cointégration	Correct
Volatilité	GARCH(1,1) Student, GJR si asymétrie	GARCH retenu, γ négatif non prévu	Incomplet
Protocole des réseaux	Scaler sur le passé, validation temporelle	Appliqué tel quel	Utile
Origine des gains	Non expliquée	Petite hausse prévue pendant un test très haussier	Non trouvé
Origines chevauchantes	Non mentionné	394 origines dépendantes	Oubli

6. Prévision et évaluation

6.1. Méthode

Tous les modèles sont évalués de la même façon sur le test :

- 394 origines communes, du 22/05/2024 à la dernière date qui permet une prévision à 10 séances ;
- horizons de 5 et 10 séances ;
- paramètres fixés sur l'apprentissage, seules les nouvelles observations sont ajoutées ;
- pour les réseaux, chaque rendement prévu est réinjecté dans la fenêtre (prévision récursive) ;
- erreurs calculées sur les prix : MSE en USD², RMSE et MAE en USD, MAPE en %.

ARIMA(0,1,0) sans dérive et le prix inchangé donnent exactement la même prévision.

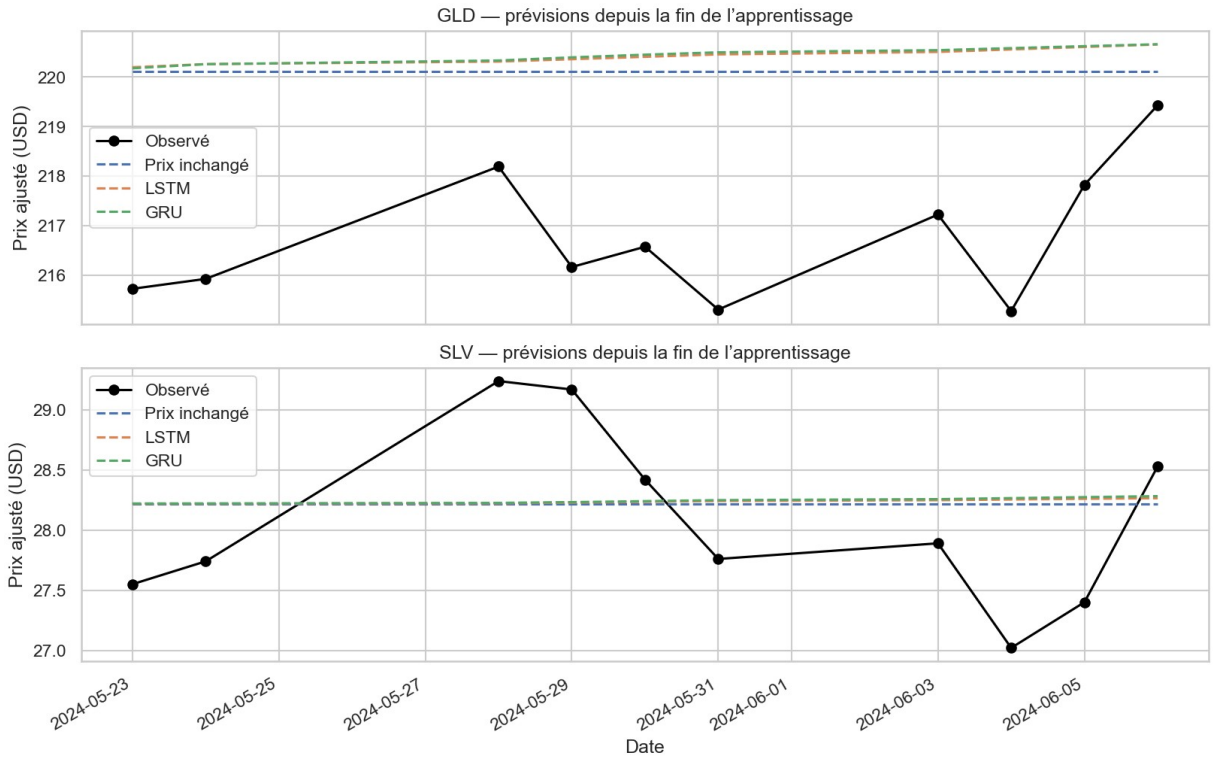


Figure 9 : Prévisions sur 10 séances depuis le 22/05/2024

Les prévisions des réseaux sont presque plates et légèrement au-dessus du dernier prix, alors que le prix réel varie beaucoup plus.

6.2. Résultats

Tableau 15 : Erreurs de prévision des prix sur le test (MSE en USD², RMSE et MAE en USD, MAPE en %)

Actif	Modèle	MSE h5	RMSE h5	MAE h5	MAPE h5	MSE h10	RMSE h10	MAE h10	MAPE h10
GLD	Prix inchangé / ARIMA(0,1,0)	58,07	7,62	5,69	1,92	114,90	10,72	8,00	2,66
GLD	VAR(0)	56,79	7,54	5,61	1,89	109,75	10,48	7,78	2,59
GLD	VAR(1)	56,73	7,53	5,61	1,89	109,65	10,47	7,78	2,59
GLD	LSTM	**56,24**	**7,50**	**5,58**	**1,88**	**108,21**	**10,40**	**7,72**	**2,56**
GLD	GRU	56,28	7,50	5,59	1,89	108,75	10,43	7,74	2,58
SLV	Prix inchangé / ARIMA(0,1,0)	2,72	1,65	1,15	3,33	7,11	2,67	1,81	4,92
SLV	VAR(0)	2,70	1,64	1,15	3,32	7,00	2,65	1,80	4,89
SLV	VAR(1)	2,70	1,64	1,15	3,32	7,00	2,65	1,80	4,89
SLV	LSTM	2,66	1,63	1,15	3,31	6,93	2,63	1,79	4,87
SLV	GRU	**2,63**	**1,62**	**1,14**	**3,30**	**6,79**	**2,61**	**1,78**	**4,85**

Le meilleur modèle de chaque colonne est en gras. ARIMA(0,1,0) sans dérive donne exactement les mêmes valeurs que le prix inchangé.

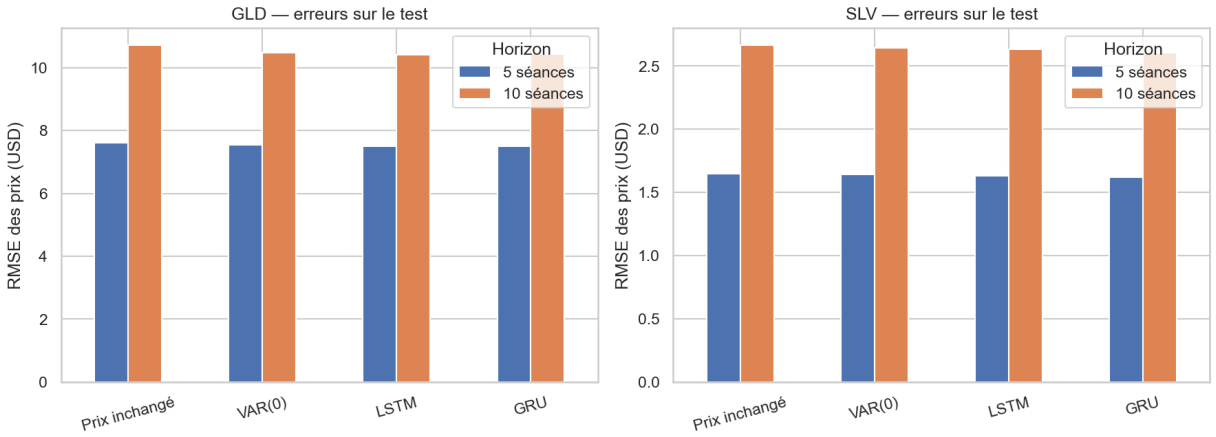


Figure 10 : RMSE des prix sur le test

Les barres sont presque de la même hauteur : les écarts entre modèles sont faibles, et l'erreur augmente nettement entre 5 et 10 séances.

Tous les modèles font un peu mieux que le prix inchangé. Le LSTM est le meilleur pour GLD et le GRU pour SLV. La baisse de RMSE par rapport au prix inchangé va de 0,4 % à 3,0 %. Pour GLD à 10 séances, le VAR(0) obtient déjà 2,3 %, contre 3,0 % pour le LSTM. L'argent reste plus difficile à prévoir (MAPE de 4,9 % à 10 séances contre 2,6 % pour l'or).

6.3. Tests de Diebold–Mariano

Le test de Diebold–Mariano vérifie si l'écart d'erreur entre deux modèles est significatif. La variance tient compte du chevauchement des horizons et les p-values sont corrigées par la méthode de Holm, car 24 comparaisons sont faites.

Tableau 16 : Statistique DM et p-value corrigée de Holm (en gras : significatif à 5 %)

Comparaison	GLD h5	GLD h10	SLV h5	SLV h10
LSTM contre Prix inchangé	−3,06 | 0,052	**−3,67 | 0,007**	−1,97 | 0,798	−1,92 | 0,839
GRU contre Prix inchangé	−1,84 | 0,941	−2,84 | 0,094	−2,02 | 0,745	−1,82 | 0,941
VAR(0) contre Prix inchangé	−3,01 | 0,059	**−3,38 | 0,019**	−2,52 | 0,229	−2,38 | 0,320
LSTM contre VAR(0)	−1,43 | 1,000	−1,78 | 0,941	−1,20 | 1,000	−1,00 | 1,000
GRU contre VAR(0)	−0,83 | 1,000	−1,13 | 1,000	−1,81 | 0,941	−1,59 | 1,000
LSTM contre GRU	−0,08 | 1,000	−0,81 | 1,000	0,82 | 1,000	1,16 | 1,000

Seules deux comparaisons sur 24 sont significatives : pour GLD à 10 séances, le LSTM ($p = 0{,}0067$) et le VAR(0) ($p = 0{,}0185$) battent le prix inchangé. Le LSTM n'est pas significativement meilleur que le VAR(0) ni que le GRU. Pour SLV, aucun gain n'est significatif.

6.4. Intervalles GARCH

Pour chaque origine, 10 000 trajectoires sont simulées avec le GARCH(1,1) Student. Les quantiles 2,5 % et 97,5 % donnent un intervalle à 95 %. La médiane théorique est égale au dernier prix. Comme les rendements sont transformés en prix par l'exponentielle, l'intervalle est asymétrique en prix : le milieu des bornes n'est donc pas égal à cette médiane.

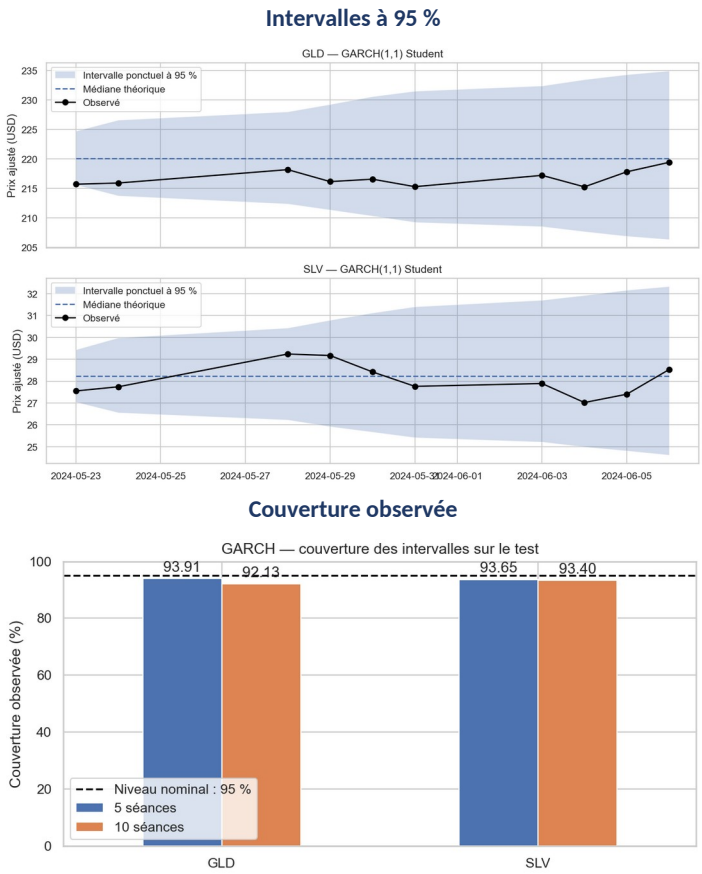


Figure 11 : Intervalles GARCH depuis le 22/05/2024 (gauche) et couverture sur le test (droite)

L'intervalle s'élargit avec l'horizon et contient bien les prix observés au départ, mais la couverture sur tout le test reste un peu sous 95 %.

Tableau 17 : Couverture des intervalles GARCH à 95 %

Actif	Horizon	Couverture	Largeur moyenne (USD)	Score moyen
GLD	5 séances	93,91 %	28,13	38,31
GLD	10 séances	92,13 %	39,71	58,54
SLV	5 séances	93,65 %	5,49	7,61
SLV	10 séances	93,40 %	7,78	10,20

La couverture observée va de 92,13 % à 93,91 %, un peu sous les 95 % visés, surtout pour GLD à 10 séances. C'est une observation descriptive : aucun test formel de calibration n'a été réalisé. Les paramètres sont fixés et des effets ARCH restent pour SLV, donc ces intervalles sont approximatifs.

6.5. Choix du modèle

Le LSTM a les meilleurs scores pour GLD et le GRU pour SLV, mais aucun réseau ne bat significativement le VAR(0). Le VAR(0) obtient l'un des deux seuls gains significatifs, se calcule instantanément et s'explique facilement. Nous retenons donc le VAR(0) pour prévoir les prix et le GARCH(1,1) Student pour mesurer le risque.

Ce choix constitue une conclusion comparative sur la période test étudiée, et non une garantie de performance future. Aucune période supplémentaire indépendante n'a été utilisée pour évaluer le modèle après cette sélection. Le GARCH reste un outil de référence pour l'incertitude, malgré les défauts de diagnostic et de couverture signalés.

7. Tableau de comparaison des modèles

Tableau 18 : Comparaison détaillée : métriques, complexité et interprétabilité (ligne surlignée : modèle retenu)

Modèle	Rôle	RMSE GLD h5 / h10	RMSE SLV h5 / h10	MAPE h10 GLD / SLV (%)	Gain RMSE GLD h5 / h10 (%)	Gain RMSE SLV h5 / h10 (%)	Test DM (Holm 5 %)	Paramètres	Coût de calcul	Interprétabilité	Limites
Prix inchangé = ARIMA(0,1,0)	Référence	7,62 / 10,72	1,65 / 2,67	2,66 / 4,92	référence	référence	Référence	1 par actif	Négligeable	Totale	Résidus non normaux, effets ARCH
VAR(0)	Prévision des prix	7,54 / 10,48	1,64 / 2,65	2,59 / 4,89	1,1 / 2,3	0,4 / 0,7	Bat le prix inchangé pour GLD h10 (p = 0,019)	5	Instantané	Très bonne : rendement moyen constant	Effets ARCH dans les résidus
VAR(1)	Test de Granger	7,53 / 10,47	1,64 / 2,65	2,59 / 4,89	1,2 / 2,3	0,4 / 0,7	Non testé	9	Instantané	Bonne	Coefficients non significatifs
LSTM	Prévision des prix	7,50 / 10,40	1,63 / 2,63	2,56 / 4,87	1,6 / 3,0	1,1 / 1,3	Bat le prix inchangé pour GLD h10 (p = 0,007), pas le VAR(0)	4 546	13 à 24 s par entraînement	Faible : boîte noire	Gain non confirmé en validation croisée
GRU	Prévision des prix	7,50 / 10,43	1,62 / 2,61	2,58 / 4,85	1,6 / 2,7	1,7 / 2,3	Aucun gain significatif	3 522	14 à 42 s par entraînement	Faible : boîte noire	Moins bon que le rendement nul en validation croisée
GARCH(1,1) Student	Volatilité						Couverture 95 % : GLD 93,9 / 92,1, SLV 93,7 / 93,4	4 par actif	Rapide, 10 000 simulations par origine	Bonne : persistance des chocs	Effets ARCH restants pour SLV
GJR-GARCH	Volatilité asymétrique						γ significatif, BIC moins bon	5 par actif	Rapide	Bonne	Non retenu

Pour GLD, le gain relatif de RMSE des réseaux par rapport au prix inchangé dépasse celui du VAR(0) de moins d'un point de pourcentage. Leur avantage sur VAR(0) n'est pas statistiquement établi par les tests réalisés. Les réseaux utilisent par ailleurs des milliers de paramètres au lieu de cinq. Le VAR(0) offre donc le meilleur équilibre entre précision, simplicité et interprétabilité.

8. Interprétation des résultats et apport des LLM

8.1. Réponses aux questions

Prévision : les prix de GLD et SLV se comportent presque comme une marche aléatoire. Les modèles battent le prix inchangé de 0,4 % à 3,0 % en RMSE, et ce gain n'est significatif que pour GLD à 10 séances. Les réseaux ne font pas significativement mieux qu'un modèle linéaire simple.

Liens entre actifs : l'or et l'argent bougent ensemble le même jour (corrélation de 0,79). Avec les spécifications retenues, les tests ne détectent ni causalité de Granger avec un retard ni cointégration.

Volatilité : elle est très persistante et plus forte pour l'argent. Les intervalles GARCH ont une couverture proche de 95 %, un peu trop étroite sur le test. Leur qualité n'a pas été comparée à une autre méthode.

8.2. Origine des gains de prévision

Entre le 22/05/2024 et le 31/12/2025, GLD monte de 80 % et SLV de 128 % : la période de test est très haussière. Le VAR(0) ajoute chaque jour le rendement moyen de l'apprentissage (+0,019 % pour GLD, +0,014 % pour SLV) et les réseaux prévoient aussi de petites hausses (+0,05 % à +0,25 % au 22/05/2024). Le caractère haussier du test peut favoriser une prévision avec une légère dérive positive. Cette explication reste une hypothèse : elle n'est pas démontrée sans analyse supplémentaire, par exemple une évaluation sur une période de baisse ou sans tendance.

8.3. Limites

- Une seule période de test, très haussière : les résultats peuvent changer sur une autre période.
- Paramètres fixés pendant tout le test, sans réestimation.
- Une seule architecture de réseau et aucune variable externe (dollar, taux d'intérêt).
- GARCH imparfait pour SLV et intervalles qui ignorent l'incertitude des paramètres.
- Aucune stratégie d'investissement testée avec les frais.

8.4. Apport des LLM

Tableau 19 : Ce que les LLM ont apporté et ce qu'ils n'ont pas su faire

Ce qu'ils ont apporté	Ce qu'ils n'ont pas su faire
La liste des tests à faire avant chaque modèle.	Expliquer l'origine des gains sur le test.
Une méthode d'évaluation des réseaux sans fuite.	Choisir les ordres (faits par l'AIC et le BIC).
Un texte clair pour un non-spécialiste.	Prévoir le γ négatif du GJR-GARCH.
Un vocabulaire prudent et juste.	Donner un avis vraiment indépendant.
Du temps gagné pour la rédaction.	Vérifier eux-mêmes les chiffres.

Les LLM ont fait gagner du temps pour structurer et rédiger, mais pas pour l'analyse elle-même : ils reformulent bien ce qu'on leur donne sans remettre en question nos interprétations.

Conclusion

Les prix de GLD et SLV sont proches d'une marche aléatoire. Sur le test, le LSTM a les meilleures métriques pour GLD et le GRU pour SLV, mais ces écarts ne sont pas significatifs face au VAR(0) : après correction de Holm, seules deux comparaisons sur 24 battent le prix inchangé. Le VAR(0) reste le meilleur compromis entre précision, simplicité et coût, et le GARCH(1,1) Student décrit la volatilité. Pour prolonger ce travail, il faudrait tester les modèles sur plusieurs périodes, dont une période de baisse, et ajouter des variables externes comme le dollar ou les taux d'intérêt.

Annexes

Les annexes contiennent les prompts envoyés au LLM et l'organisation du dépôt.

Annexe A. Prompts envoyés au LLM

Les grilles de critique du groupe (04, 07 et 10) et la synthèse (01) sont dans `reports/llm/`. Les tableaux de chiffres des prompts 2 et 3 sont ceux de la section 6 et sont abrégés ici ; les réponses du LLM sont reproduites en entier.

Les tableaux sont abrégés dans cette annexe pour limiter sa longueur. Les prompts complets, avec tous les chiffres transmis, et les réponses intégrales sont conservés dans `reports/llm/`.

A.1. Hypothèses de modèles (02_prompt_hypotheses.txt)

Prompt :

```
Je réalise un projet de séries temporelles sur GLD et SLV,
deux instruments donnant une exposition à l'or et à l'argent.

Les observations sont quotidiennes, par séance boursière.
L'historique couvre 2010–2025 et les derniers 10 % sont réservés
au test. Les tableaux ci-dessous concernent uniquement
la période d'apprentissage.

Les rendements sont calculés comme :
100 × différence du logarithme des prix ajustés.
La kurtosis présentée est un excès de kurtosis.

STATISTIQUES DES RENDEMENTS
     Moyenne (%)  Écart-type (%)  Variance  Minimum (%)  Maximum (%)  Asymétrie  Excès de kurtosis
GLD     0.019212        0.977263  0.955044    -9.190507     4.787391  -0.501465           4.995916
SLV     0.013629        1.820814  3.315364   -15.252920     8.748747  -0.716639           7.079888

TESTS DE STATIONNARITÉ
Actif    Série Spécification  ADF statistique  ADF p-value  ADF retards  KPSS statistique  KPSS p-value  KPSS
retards
  GLD  Log-prix           c       -0.969130     0.764356          0         3.438896         0.01          38
  GLD  Log-prix          ct       -1.463296     0.841364          0         1.535507         0.01          38
  GLD Rendement           c      -60.607564     0.000000          0         0.138119         0.10           5
  SLV  Log-prix           c       -1.849578     0.356140          0         1.969996         0.01          38
  SLV  Log-prix          ct       -1.823687     0.693226          0         1.308746         0.01          38
  SLV Rendement           c      -59.032185     0.000000          0         0.100892         0.10           2

À partir de ces informations :
1. Propose des hypothèses de modèles de moyenne et de volatilité
   à tester, en justifiant chaque proposition.
2. Précise les diagnostics supplémentaires nécessaires avant
   de retenir ARIMA, SARIMA, VAR, VECM ou GARCH.
3. Explique comment comparer LSTM et GRU aux modèles classiques
   sans fuite d'information.
4. Distingue les conclusions soutenues par les tableaux des
   hypothèses qui restent à vérifier.

N'invente aucun résultat, aucune p-value ni aucune causalité.
Ne suppose pas une saisonnalité ou une cointégration non testée.
Ne formule pas de recommandation d'investissement à cette étape.
```

Réponse du LLM (03_reponse_hypotheses.md) :

Les tableaux soutiennent une modélisation des log-prix avec une première différenciation et des rendements sans différenciation supplémentaire. Ils motivent aussi l'étude de distributions à queues épaisses. Ils ne suffisent pas à choisir les ordres des modèles ni à établir la présence d'effets GARCH.

1. Hypothèses de modèles à tester

Composante	Candidats	Justification
Moyenne univariée	ARIMA(0,1,0) sur les log-prix, avec et sans dérive	Référence simple compatible avec les résultats de stationnarité
Dépendance des rendements	Petits modèles ARMA(p,q), équivalents à des ARIMA(p,1,q) des log-prix	À tester si les ACF/PACF révèlent une dépendance temporelle
Moyenne multivariée	VAR sur les rendements de GLD et SLV	Permet de tester une information prédictive croisée, non établie par les tableaux
Relation de long terme	VECM, uniquement si une cointégration est détectée	La non-stationnarité individuelle ne démontre pas une relation d'équilibre
Volatilité	GARCH(1,1) avec innovations de Student, si des effets ARCH sont détectés	Les queues épaisses rendent la Student pertinente comme candidate
Volatilité asymétrique	GJR-GARCH ou EGARCH	À envisager si les diagnostics montrent une réponse différente aux chocs positifs et négatifs

Une moyenne empirique positive ne démontre pas une dérive significative. De même, l'asymétrie négative des rendements ne prouve pas une asymétrie de la volatilité conditionnelle.

2. Diagnostics nécessaires

- ARIMA : examiner ACF/PACF des rendements, comparer des ordres modestes par AIC/BIC, vérifier la convergence, puis tester les résidus avec Ljung–Box, Jarque–Bera et ARCH-LM. - SARIMA : rechercher d'abord une saisonnalité reproductible, par graphiques, décomposition et autocorrélations aux retards pertinents. Une semaine de cinq séances ne suffit pas à justifier une saisonnalité. - VAR : vérifier l'alignement des séries, sélectionner les retards par critères d'information et contrôler la stabilité lorsque le modèle comporte des retards. Examiner la blancheur multivariée, la normalité et les effets ARCH des résidus. Une causalité de Granger indique une dépendance prédictive, pas une causalité économique. - VECM : confirmer que les séries sont compatibles avec une intégration I(1), tester la cointégration avec une spécification déterministe justifiée et vérifier la sensibilité aux retards et aux ruptures. - GARCH : examiner les rendements ou résidus au carré et appliquer ARCH-LM avant estimation. Après estimation, vérifier convergence, contraintes des paramètres et diagnostics des résidus standardisés et de leurs carrés. Évaluer également les prévisions de variance ou la couverture des intervalles hors échantillon.

Les fortes valeurs extrêmes doivent être vérifiées avant toute correction ; elles peuvent représenter des mouvements authentiques.

3. Comparaison de LSTM et GRU sans fuite d'information

Conserver les derniers 10 % comme test final et effectuer les choix d'architecture uniquement dans les premiers 90 %, avec une validation temporelle à historique croissant.

Pour chaque découpage :

1. Ajuster le scaler uniquement sur les observations utilisées pour entraîner le réseau. 2. Construire chaque fenêtre avec des observations antérieures à sa cible. 3. Utiliser une validation interne pour l'arrêt anticipé et un bloc ultérieur distinct pour l'évaluation. 4. Réinitialiser les poids des réseaux entre les découpages.

Comparer tous les modèles sur les mêmes origines, cibles et horizons, avec un protocole identique d'actualisation des observations et de réestimation des paramètres. Pour une prévision récursive à plusieurs séances, réinjecter les prévisions plutôt que les rendements futurs réels.

Inclure une référence de rendement nul, correspondant à un prix inchangé. Calculer MSE, RMSE et MAE sur les rendements ou les prix, en précisant l'unité ; réserver de préférence la MAPE aux prix positifs, car elle devient instable pour des rendements proches de zéro. Documenter le coût de calcul et la sensibilité aux graines aléatoires. Un test de Diebold–Mariano doit tenir compte du chevauchement des horizons.

4. Conclusions établies et hypothèses restantes

Les tableaux montrent :

- Une dispersion plus élevée pour SLV : son écart-type quotidien est de 1,820814 %, contre 0,977263 % pour GLD. - Une asymétrie empirique négative et un excès de kurtosis positif pour les deux actifs. - Des résultats ADF et KPSS concordants avec des log-prix non stationnaires et des rendements stationnaires. Cela soutient une intégration I(1) des log-prix, sans constituer une preuve définitive.

Les p-values ADF affichées à `0,000000` sont arrondies. Les valeurs KPSS de `0,01` et `0,10` peuvent correspondre aux bornes des tables utilisées ; elles ne doivent pas être interprétées comme des probabilités exactes.

Restent à vérifier : les ordres AR/MA, une éventuelle saisonnalité, les effets ARCH, l'asymétrie conditionnelle, la cointégration, les relations prédictives croisées et la supériorité des réseaux. Les tableaux descriptifs et de stationnarité ne permettent pas, à eux seuls, de conclure sur ces points.

A.2. Explication pour un décideur (05_prompt_vulgarisation.txt)

Prompt (tableaux de chiffres abrégés) :

```
Explique les résultats de mon étude GLD/SLV à un décideur
non statisticien, en français, en 400 à 600 mots.

PROTOCOLE
Les modèles sont estimés sur les premiers 90 % de l'historique.
LSTM et GRU ont été évalués par validation croisée temporelle.
Sur le test final, les prévisions utilisent 394 origines communes,
aux horizons de 5 et 10 séances. Les paramètres restent fixes,
mais les observations disponibles sont actualisées à chaque origine.

Les métriques ci-dessous portent sur les prix à l'échéance exacte.
ARIMA(0,1,0) sans dérive et prix inchangé donnent les mêmes prévisions.

MÉTRIQUES SUR LE TEST
[tableau abrégé, voir le fichier]

TESTS DE DIEBOLD–MARIANO
La perte comparée est l'erreur quadratique.
La variance est estimée par HAC ; la correction de Holm
porte sur les 24 comparaisons.
[tableau abrégé, voir le fichier]

INTERVALLES GARCH
Intervalles ponctuels nominaux à 95 %, simulés avec innovations
de Student. Les paramètres sont fixes et leur incertitude
d'estimation n'est pas intégrée.
Actif  Horizon   N  Couverture_pct  Largeur_moyenne_USD  Score_moyen
  GLD        5 394       93.908629            28.132106    38.305739
  GLD       10 394       92.131980            39.714791    58.535340
  SLV        5 394       93.654822             5.487049     7.614444
  SLV       10 394       93.401015             7.783514    10.203909

LIMITES CONNUES
La validation temporelle ne montre pas un avantage régulier
des réseaux face au rendement nul.
Des effets ARCH résiduels persistent après estimation GARCH,
particulièrement pour SLV.
Aucune stratégie de trading ni rentabilité après frais n'a été testée.

CONSIGNES
- Explique les rôles différents de la prévision du prix et de GARCH.
- Distingue meilleur score numérique et différence significative.
- Compare précision, simplicité et coût de calcul sans inventer
  de mesures de temps.
- Explique les couvertures observées sans affirmer qu'un test
  formel de calibration a été réalisé.
- Une différence non significative ne prouve pas l'équivalence.
- N'invente aucune valeur ni causalité.
- Ne donne pas encore de recommandation d'investissement.
```

Réponse du LLM (06_reponse_vulgarisation.md) :

L'étude montre que les modèles les plus complexes améliorent certains scores de prévision, mais leur avantage n'est pas systématiquement établi. Elle distingue deux besoins : prévoir un niveau de prix et mesurer l'incertitude autour de ce prix. La comparaison repose sur 394 dates de départ communes, avec des prévisions à cinq et dix séances boursières. Les paramètres des modèles restent fixes pendant le test, tandis que les nouvelles observations disponibles alimentent les prévisions suivantes. Ce protocole permet de comparer les méthodes dans les mêmes conditions, sans utiliser les prix futurs au moment de prévoir. La référence la plus simple consiste à prévoir un prix inchangé. L'ARIMA retenu, sans dérive, donne exactement cette même prévision. Le VAR(0) ajoute un rendement moyen estimé sur l'apprentissage ; malgré son nom multivarié, il n'utilise aucun rendement passé pour anticiper la séance suivante. LSTM et GRU cherchent, eux, des relations dans des fenêtres de rendements passés. Pour GLD, le LSTM obtient les meilleures erreurs parmi les modèles comparés. À dix séances, son erreur absolue moyenne est d'environ 7,72 USD, contre 8,00 USD pour le prix inchangé et 7,78 USD pour le VAR(0). Il améliore donc la précision numérique, mais l'écart avec le VAR(0) est limité. Pour SLV, le GRU obtient les meilleurs scores aux deux horizons. À dix séances, son erreur absolue moyenne atteint environ 1,78 USD, contre 1,81 USD pour le prix inchangé. Les erreurs relatives moyennes restent plus élevées pour SLV que pour GLD. Les erreurs en dollars ne doivent toutefois pas être comparées directement entre les deux actifs, dont les niveaux de prix diffèrent. Les tests statistiques nuancent ces classements. Après correction des 24 comparaisons, seules deux améliorations restent significatives : pour GLD à dix séances, le LSTM et le VAR(0) font mieux que le prix inchangé. Aucun avantage significatif du LSTM face au VAR(0), ni du LSTM face au GRU, n'est établi. Pour SLV, les gains numériques ne restent pas significatifs après correction. Cela ne prouve pas que les modèles sont équivalents : les données et le test ne permettent simplement pas de distinguer leurs performances avec suffisamment de certitude. Le GARCH répond à une autre question : quelle amplitude de fluctuations faut-il envisager ? Ses intervalles annoncés à 95 % couvrent environ 92,13 % à 93,91 % des prix observés. Ils présentent donc une sous-couverture descriptive sur cette période, particulièrement pour GLD à dix séances. Aucun test formel de calibration n'a cependant été réalisé. Les intervalles s'élargissent avec l'horizon, mais ignorent l'incertitude d'estimation des paramètres ; des effets de volatilité restent également présents dans les résidus. Le choix d'un outil doit ainsi tenir compte de la précision et de sa complexité. Le VAR(0) est simple à expliquer et à calculer. Les réseaux

demandent davantage d'entraînement et de suivi, sans avantage régulier lors de la validation temporelle. Le LSTM conserve le meilleur score pour GLD sur ce test, mais sa complexité supplémentaire n'apporte pas de supériorité statistique démontrée face au VAR(0). Enfin, ces résultats évaluent la prévision et l'incertitude, pas la rentabilité d'une stratégie après frais.

A.3. Recommandations simulées (08_prompt_recommandations.txt)

Prompt (tableaux de chiffres abrégés) :

```
Dans un exercice pédagogique, place-toi au 2024-05-22,
à la clôture. Propose des recommandations d'investissement simulées
pour GLD et SLV aux horizons de 5 et 10 séances.

PRÉVISIONS DISPONIBLES À CETTE DATE
[tableau abrégé, voir le fichier]

INTERVALLES GARCH PONCTUELS À 95 %
Actif  Horizon  Mediane theorique  Borne basse 95 %  Borne haute 95 %
  GLD        5         220.110001        210.346752        230.592337
  GLD       10         220.110001        206.358877        234.938624
  SLV        5          28.219999         25.674490         31.121380
  SLV       10          28.219999         24.623281         32.332263

CONTEXTE DISPONIBLE
Les réseaux utilisent une fenêtre de 30 rendements passés.
La validation temporelle réalisée avant cette date ne montre
pas un avantage régulier face au rendement nul.
Les diagnostics GARCH sur l'apprentissage indiquent des effets
ARCH résiduels, particulièrement pour SLV.
Aucune stratégie de trading après frais n'a été évaluée.

CONSIGNES
1. Propose pour chaque actif une position simulée justifiée :
   achat, vente ou abstention. L'abstention est une option valable.
2. Relie les propositions aux variations prévues et à l'incertitude.
3. Explique les limites : désaccord entre modèles, erreurs possibles,
   frais, liquidité, changements de régime et estimation du risque.
4. Distingue les prévisions de prix des intervalles GARCH :
   ces derniers ne sont pas des intervalles autour du LSTM ou du GRU.
5. Ne transforme pas les intervalles en garantie de résultat.
6. N'invente pas de probabilité de hausse, de rendement garanti,
   de seuil optimal ni de montant à investir.
7. N'utilise aucune observation ni performance postérieure
   à la date de décision. Ne recherche pas d'informations externes.

Présente une réponse concise, avec un tableau de décisions simulées
et une explication des risques. Il s'agit d'un scénario historique,
pas d'une recommandation actuelle.
```

Réponse du LLM (09_reponse_recommandations.md) :

Au 22 mai 2024 à la clôture, l'abstention est la décision simulée retenue pour les deux actifs aux deux horizons. Les réseaux prévoient de faibles hausses, mais leur avantage prédictif n'est pas régulier dans la validation disponible à cette date.

Actif	Horizon	Variation prévue LSTM / GRU	Décision simulée	Justification
GLD	5 séances	+0,136 % / +0,155 %	Abstention	Signal positif faible ; la référence prévoit un prix inchangé et l'incertitude GARCH est large.
GLD	10 séances	+0,249 % / +0,251 %	Abstention	Les réseaux concordent, mais cette concordance ne démontre pas une occasion rentable après frais.
SLV	5 séances	+0,054 % / +0,074 %	Abstention	Hausse prévue très limitée face à l'amplitude des fluctuations envisagées.
SLV	10 séances	+0,161 % / +0,222 %	Abstention	Signal modeste, avec un risque imparfaitement décrit par le GARCH.

Les prévisions ponctuelles indiquent une direction légèrement haussière. Elles ne fournissent ni une probabilité de hausse ni une garantie de gain. Le prix inchangé reste une référence concurrente ; LSTM et GRU utilisent les mêmes données, donc leur accord ne constitue pas deux confirmations indépendantes. Les intervalles GARCH décrivent séparément l'incertitude des prix sous un modèle de rendements à moyenne nulle. Pour GLD, ils vont de 210,35 à 230,59 USD à cinq séances et de 206,36 à 234,94 USD à dix séances. Pour SLV, les bornes sont respectivement 25,67–31,12 USD et 24,62–32,33 USD. Ces amplitudes sont importantes face aux petites variations prévues par les réseaux. Toutefois, ces intervalles ne sont pas des intervalles autour des prévisions LSTM ou GRU, et leur largeur ne constitue pas, à elle seule, un test de rentabilité. Les frais, les écarts entre prix d'achat et de vente et les conditions de liquidité pourraient absorber les faibles gains envisagés ; leur effet n'a pas été mesuré. Des changements de régime ou des événements nouveaux peuvent également dégrader les prévisions. Enfin, les effets ARCH résiduels, particulièrement pour SLV, signalent que le modèle de risque reste incomplet. L'abstention signifie ici ne pas ouvrir de nouvelle position sur la seule base de ces signaux. Elle ne préjuge pas de la gestion d'une position existante, qui nécessiterait des informations sur ses objectifs et contraintes. Cette décision pédagogique repose exclusivement sur les éléments fournis disponibles au 22 mai 2024.

Annexe B. Organisation du dépôt

Élément	Contenu
notebooks/01_or_argent.ipynb	Notebook principal (sections 1 à 9) : données, exploration, modèles, réseaux, évaluation, LLM
scripts_R/02_modeles_classiques.R	Réestimation des modèles classiques en R (ARIMA, VAR, Granger, Johansen, GARCH, prévisions glissantes)
data/raw/	Données brutes Yahoo Finance de GLD et SLV (OHLC, Adj Close, Volume)
data/processed/	Tableaux intermédiaires et résultats (CSV) ; sous-dossier r/ pour les sorties R
figures/	Graphiques du notebook ; sous-dossier r/ pour les graphiques R
models/	Réseaux finaux (.keras), scaler (.joblib), objets R (.rds)
reports/llm/	Prompts, réponses intégrales et grilles de critique des consultations LLM
reports/r/	Résumés des estimations R et informations de session
Environnements	Python : TensorFlow 2.21, scikit-learn 1.7.2, statsmodels, pmdarima, arch ; R 4.6.1 : forecast, vars, urca, tseries, rugarch, FinTS